

Modèles de régression linéaire et outils du diagnostic (suite) - TW133MI

S. Lèbre

M1 MIAHS

Chap 8 : Validation du modèle linéaire

Introduction

Votre modèle est-il valide ?

Cela dépend !

Notamment des relations présentes dans les données.

Avant d'utiliser un modèle, assurons-nous que les données sont en adéquation avec les pré-supposés de ce modèle.

=> Dans le cas contraire, cela pourrait nous mener à des conclusions erronées.

Nous considérons ici le cas du modèle linéaire multiple :

$$Y = X\beta + \varepsilon$$

(Si le modèle suppose une constante et p caractéristiques, la matrice X est constituée de $p + 1$ colonnes.)

Validation du modèle linéaire

Les données sont-elles en adéquation avec les présupposés du modèle linéaire ?

Choix de modélisation / Pré-supposés

- ▶ Le lien entre la réponse Y et les p variables explicatives $X_1, \dots, X_p$ est-il linéaire ?
- ▶ Y a-t-il des caractéristiques (ou features) redondantes au sein de la matrice X ?
- ▶ Toutes les caractéristiques (ou features) sont-elles présentes pour expliquer Y ?

Observations atypiques

- ▶ Y a-t-il des observations atypiques dans les données?
- ▶ Y a-t-il des observations "très" influentes ?

Validation du modèle linéaire (2)

Pour démarrer, rappeler les 3 hypothèses sur lesquelles repose le modèle linéaire :

$$Y = X\beta + \varepsilon$$

(H_1)

(H_2)

(H_3)

Rappel des 3 Hypothèses

- ▶ (H_1) : X est une matrice de plein rang, c'est-à-dire

$$\text{rang}(X) = p + 1.$$

- ▶ (H_2) : Les erreurs ε_i sont centrées, de même variance et non corrélées entre elles.

$$E(\varepsilon) = 0_n \text{ et } \Sigma_\varepsilon = \sigma^2 I_n,$$

où 0_n est le vecteur colonne de zéros (de taille n) et I_n est la matrice identité d'ordre n .

- ▶ (H_3) : Les erreurs ε_i sont gaussiennes, c'est-à-dire que pour tout i ,

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

Linéarité

Le modèle de régression linéaire impose que la prédiction soit une **combinaison linéaire des caractéristiques**, ce qui est à la fois sa plus grande force et sa plus grande limitation.

- ▶ La linéarité permet d'obtenir des modèles interprétables.
- ▶ Les effets linéaires sont faciles à quantifier et à décrire. Ils sont additifs, ce qui facilite la distinction des effets.
- ▶ L'hypothèse linéaire est souvent acceptable en grande dimension (permet de capturer les principaux liens entre les variables).

mais il existe des liens non-linéaires !

Caractéristiques fixes

Les caractéristiques d'entrée X ou *features* (aussi appelées variables explicatives ou prédicteurs) sont considérées comme « fixes ».

Fixes signifie qu'elles sont traitées comme des constantes données et non comme des variables statistiques, ce qui implique qu'elles sont exemptes d'erreurs de mesure. Cette hypothèse est assez irréaliste.

Sans cette hypothèse, toutefois, on devrait ajuster des modèles d'erreur de mesure très complexes pour tenir compte des erreurs de mesure dans vos caractéristiques d'entrée, ce qui est souvent indésirable.

Utilisons les estimations pour observer le modèle à la loupe !

Principales fonctions R pour la régression linéaire

```
# simulation d'un modèle linéaire avec 3 variables
```

```
p=3
```

```
n=200
```

```
x <- matrix(data = rnorm(n*p), ncol = p)
```

```
beta = matrix(c(1,3,-2,1), ncol=1)
```

```
y <- beta[1]+ x %*%beta[-1] +rnorm (n)
```

```
# conversion en data.frame
```

```
data<- as.data.frame(cbind(x,y))
```

```
names(data)<- c(paste(c("x"),1:p,sep=""), "y")
```

```
plot(x[,1],y) # nuage de points (x1, y)
```

```
plot(data) # tous les nuages de points 2 à 2
```

```
# regression linéaire
```

```
reg<- lm(y~x) # estimation du modèle linéaire
```

```
summary(reg) #description des résultats du modèle
```

```
confint(reg) # intervalle de confiance des paramètres de régression
```

```
head(reg$coefficients) # valeurs des coefficients estimés
```

```
head(reg$residuals) # résidus estimés
```

```
head(reg$fitted.values) # prédictions pour y
```

```
plot(reg) #analyse graphique des résidus
```

Plan du chapitre 8

1. Rang de X et colinéarité entre les prédicteurs
2. Colinéarité entre les prédicteurs
3. Graphes des résidus
4. Graphes des résidus partiels
5. Identifier les observations influentes
6. EN BREF
7. Quelques packages R bien utiles

8.1 Rang de X et colinéarité entre les prédicteurs

Pourquoi est-ce si important ?

- Inversion de la matrice $X^T X$

$$\hat{y} = (\hat{y}_i)_{1 \leq i \leq n} = X\hat{\beta} = X(X^T X)^{-1}X^T y$$


- Point de vue géométrique : La régression linéaire est une **projection orthogonale** dans un **sous-espace** de dimension $p + 1$ (le nombre de variables explicatives + 1 si constante)

Projection orthogonale dans un sous espace de dim $p + 1$

Le vecteur $\hat{y}$ est une observation de la variable aléatoire $\hat{Y}$:

$$\hat{y} = (\hat{y}_i)_{1 \leq i \leq n} = X\hat{\beta} = X(X^T X)^{-1}X^T y = Hy$$


où $H = X(X^T X)^{-1}X^T$ est la **matrice de projection orthogonale** sur le sous espace engendré par les colonnes de X , aussi appelée la **matrice chapeau** ou **Hat Matrix**.



Projection orthogonale dans un sous espace de dim $p + 1$

$\hat{y}$ est le vecteur des **valeurs ajustées** dans **l'espace des $p + 1$ colonnes de X** :

- ▶ les x_j engendrent un espace $(p + 1)$ -dimensionnel,
- ▶ $\hat{y} = Hy$ est une combinaison linéaire des colonnes x_j ,
- ▶ $\hat{\varepsilon} = y - \hat{y}$ est orthogonal à ce sous-espace.



C'est une 'régression' vers un sous-espace de dimension $p + 1$ (plus petit que n , la dimension de y !)

Projection orthogonale dans un sous espace de $\dim p + 1$

- ▶ On veut vérifier l'hypothèse que X est de **plein rang**, i.e. que les $p + 1$ colonnes de X engendrent un **sous espace vectoriel de $\mathbb{R}^n$ de dimension $p + 1$** .
- ▶ Si ce n'est pas le cas, la matrice $X^T X$ n'est pas inversible, il n'y a donc **pas de solution unique** à l'équation

$$X^T Y = X^T X \beta$$

- ▶ On veut donc vérifier qu'il n'y **pas de multicolinéarité** entre les colonnes $1, X_1, \dots, X_p$ de la matrice X .

Rang de X

Avant toute estimation, calculons le rang de la matrice X :

```
p=6
n=200
# exemple où les colonnes de x sont indépendantes
x <- matrix(data = rnorm(n*p), ncol = p)
x_un=cbind(1,x)
qr(x_un)$rank
```

```
## [1] 7
```

Remarques :

- ▶ Pour que X soit de rang $p + 1$, il faut : $n > p + 1$.
- ▶ Si $n > p + 1$, la matrice X est très souvent de plein rang (une colinéarité parfaite est rare !)


=> Etudions la colinéarité entre les prédicteurs (matrice des corrélations 2 à 2)

Matrice des corrélations 2 à 2

```
cor_mat=cor(x)  
library(corrplot)
```

```
## corrplot 0.95 loaded
```

```
corrplot(cor_mat, type="upper", order="hclust", tl.col="black", tl.srt=45)
```



8.2 Colinéarité entre les prédictors

Soit le modèle linéaire suivant :

$$Y = X\beta + \varepsilon$$

Pourquoi la présence colinéarité entre les prédictors est un problème ?

On peut montrer que :

- ▶ L'estimateur $\hat{\beta}_j$ du coefficient associé à X_j est **proportionnel à la corrélation partielle entre X_j et Y sachant les autres caractéristiques $(X_k)_{k \neq j}$** :

$$\hat{\beta}_j \propto \text{cor}(X_j, Y \mid (X_k)_{k \neq j})$$

Rappel : Corrélation partielle

Les corrélations partielles sont des outils importants mettant en jeu deux variables X_1 et X_2 , ainsi qu'un groupe de k variables contenues dans une matrice Z .

L'objectif est de mesurer la corrélation entre les variables X_1 et X_2 auxquelles on a enlevé la partie explicable par les variables de Z .

- Pour ce faire, on calcule le vecteur de coefficients $b_{X_1|Z}$ de la régression de X_1 en Z , et le vecteur de coefficients $b_{X_2|Z}$ de la régression de X_2 en Z .

$$X_1 = b_{X_1|Z}Z + \varepsilon_{X_1|Z}$$

$$X_2 = b_{X_2|Z}Z + \varepsilon_{X_2|Z}$$

- Le coefficient de corrélation partielle $cor(X_1, X_2 \mid Z)$ est le coefficient de corrélation entre les deux vecteurs de résidus $\varepsilon_{X_1|Z}$ et $\varepsilon_{X_2|Z}$:

$$cor(X_1, X_2 \mid Z) = cor(\varepsilon_{X_1|Z}, \varepsilon_{X_2|Z})$$

Effet de la présence de colinéarité entre prédicteurs

Soit le modèle linéaire suivant :

$$Y = X\beta + \varepsilon$$

Pourquoi la présence colinéarité entre les prédicteurs est un problème ?

On peut montrer que :

- ▶ L'estimateur $\hat{\beta}_j$ du coefficient associé à X_j est **proportionnel à la corrélation partielle entre X_j et Y sachant les autres caractéristiques $(X_k)_{k \neq j}$** :

$$\hat{\beta}_j \propto \text{cor}(X_j, Y \mid (X_k)_{k \neq j})$$

$\Rightarrow \hat{\beta}_j$ est l' "effet" de X_j sur Y une fois retiré l'effet des autres caractéristiques $(X_k)_{k \neq j}$

Effet de la présence de colinéarité entre prédicteurs

Soit le modèle linéaire suivant :

$$Y = X\beta + \varepsilon$$

Pourquoi la présence colinéarité entre les prédicteurs est un problème ?

On peut montrer que :

- ▶ L'estimateur $\hat{\beta}_j$ du coefficient associé à X_j est **proportionnel à la corrélation partielle entre X_j et Y sachant les autres caractéristiques $(X_k)_{k \neq j}$** , notée $cor(X_j, Y \mid (X_k)_{k \neq j})$

$\Rightarrow \hat{\beta}_j$ est l' "effet" de X_j sur Y une fois retiré l'effet des autres caractéristiques $(X_k)_{k \neq j}$

- ▶ La covariance entre les estimateurs $\hat{\beta}_i$ et $\hat{\beta}_j$ vaut :

$$cov(\hat{\beta}_i, \hat{\beta}_j) \propto -cor(X_i, X_j \mid X_k, k \neq i, j)$$

$\Rightarrow$ Les caractéristiques **fortement corrélées** impliquent des **covariances négatives** entre les coefficients de régression associés.

Effet de la présence de colinéarité entre prédicteurs

Point de vue statistique : Les coefficients associés aux variables corrélées ne sont **pas bien estimés**.

En effet, ces variables portent **une part d'information commune** dans le modèle.

- ▶ A l'extrême, avec une variable dupliquée X :

$$Y = \beta_0 + \beta_1 X + \beta_2 X + \varepsilon = \beta_0 + (\beta_1 + \beta_2)X + \varepsilon$$

=> Les coefficients β_1 et β_2 ne sont pas identifiables (Il existe une infinité de solutions).

- ▶ Les variables fortement corrélées **se partagent l'importance** dans le modèle (cf. diapo précédente : $\text{cov}(\hat{\beta}_i, \hat{\beta}_j)$).

=> Les coefficients peuvent même avoir des signes opposés.

- ▶ Certains **coefficients ont une grande variance**, et peuvent passer sous le seuil de sélection de significativité des coefficients, ou alors se placent en retrait par rapport à d'autres coefficients.

Effet de la présence de colinéarité entre prédicteurs

Point de vue numérique (optimisation) : Les variables corrélées induisent un **mauvais conditionnement** de $X^T X$.

- ▶ Difficulté de convergence
- ▶ Manque de précision de l'estimation.

Conclusion : En cas de colinéarité entre les prédicteurs :

- ▶ L'interprétation devient problématique.
- ▶ La qualité de la prédiction est détériorée.

=> Solution : **analyse spectrale** de la matrice des corrélations 2 à 2 de la matrice X .

Valeurs propres de la matrice des corrélations 2 à 2

On définit la matrice R des corrélations empiriques entre les variables X_j , $j = 1, \dots, p$:

$$R_{jj'} = \frac{\sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ij'} - \bar{x}_{j'})}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2 (x_{ij'} - \bar{x}_{j'})^2}} = \text{Corr}(x_j, x_{j'})$$

C'est une matrice symétrique positive de rang = $\dim(\text{vect}(X)) \leq p$ ($< p$ si il y a colinéarité).

- ▶ On calcule les p **valeurs propres** $\lambda_1 \geq \dots \geq \lambda_p$ de cette matrice.
- ▶ S'il y a une relation linéaire parfaite entre un ensemble de variables X_j , alors une des valeurs propres vaut 0.
- ▶ On utilise l'**indice de conditionnement**

$$\kappa = \lambda_1 / \lambda_p$$

Règle courante : $\kappa > 500 \Rightarrow$ Colinéarité trop forte.

Calcul de l'indice de conditionnement κ

- ▶ Calcul de la matrice de corrélation

```
cor_mat = cor(x)
```

- ▶ Calcul des valeurs propres

```
vp=eigen(cor_mat)  
round(vp$values,2)
```

```
## [1] 1.27 1.09 1.04 0.94 0.89 0.78
```

- ▶ Vérifier le conditionnement (calcul de κ)

```
round(vp$values[1]/vp$values[length(vp$values)])
```

```
## [1] 2
```

Recherche de multi-colinéarité

En cas de mauvais conditionnement de la matrice des corrélations, il faut agir avant de passer à l'estimation !

=> Identifier les liens entre les variables

=> Recherche de multi-colinéarité

- ▶ Calcul du **VIF (facteur d'inflation de la variance)** pour chaque variable explicatives

VIF et propriété d'inflation de variance

Considérons la régression de la variable explicative X_j sur l'ensemble des $p - 1$ autres régresseurs $X_1, \dots, X_{j-1}, X_{j+1}, \dots, X_p$:

$$X_j = a_0 + a_1 X_1 + \dots + a_{j-1} X_{j-1} + a_{j+1} X_{j+1} + \dots + a_p X_p + \epsilon$$

On note R_j^2 le R^2 (coefficient de détermination) associé à cette régression.

- ▶ Si R_j^2 est proche de 0, X_j n'est pas fonction linéaire des autres variables
- ▶ Si R_j^2 est proche de 1, X_j est bien expliquée par les autres variables $\Rightarrow$ **présence multi-colinéarité**

VIF et propriété d'inflation de variance

Un critère utilisé pour juger de la colinéarité entre les variables explicatives est le **facteur d'inflation de la variance** ou **VIF**.

On définit les coefficients VIF_j pour $j = 1, \dots, p$ par :

$$VIF_j = \frac{1}{1 - R_j^2}$$

=> Plus x_j est colinéaire aux autres régresseurs, plus R_j^2 est proche de 1, et donc plus le VIF_j élevé.

De plus, on montre que :

$$Var(\hat{\beta}_j) = \frac{\sigma^2}{||x_j - \bar{x}_j||^2} \frac{1}{1 - R_j^2}.$$

=> Plus le VIF_j est élevé, plus la variance de l'estimateur $\hat{\beta}_j$ est alors très élevée.

Règle courante On estime qu'il y a une forte colinéarité lorsque $VIF_j > 10$ (c'est-à-dire $R_j^2 > 0.9$).

Calcul du VIF (Variance Inflation Factor) avec R

```
reg<-lm(y~x)
library(car)
vif(reg)
```

Solutions en présence de colinéarité

- ▶ Calcul du **VIF** de chaque variable explicative X_j .
- ▶ Recours à l'**ACP** pour identifier/interpréter les liens entre les variables.
- ▶ Analyse spectrale de la matrice des corrélations 2 à 2 : étudier les **vecteurs propres associés aux plus petites valeurs propres**.
- ▶ Ecarter ou regrouper certains prédicteurs (VIF et/ou ACP)
 - Attention, il faut retirer les variables posant problème une à une.
 - Idéalement, le choix des variables devrait se faire avec ceux qui ont fourni le jeu de données.
- ▶ Considérer une régression sur composantes principales (ACP) ou une régression Partiel Least Square (PLS).

Solutions en présence de colinéarité

► Sélection de variables

Si le vrai modèle sous-jacent ne contient que peu de prédicteurs réellement liés à la variable réponse, on peut vouloir sélectionner ceux ayant un grand pouvoir prédictif.

On vise ainsi :

- de meilleures performances prédictives,
- une meilleure interprétabilité du modèle. (Attention, on peut alors écarter des variables alors qu'elles sont en réalité impliquées dans le phénomène observé).

Solutions en présence de colinéarité

► Régularisation

Une solution est de régulariser le problème en contraignant les paramètres dans un espace approprié (pénalité en norme L1 (LASSO) ou L2 (Ridge), voir cours 'Régularisation et optimisation des modèles' au S1) de façon à :

- stabiliser l'estimation (moins de variance)
- faciliter l'interprétabilité (sélection de variable avec la norme L1)

8.3 Graphes des résidus

La vérification de (H_1) repose uniquement sur la matrice X (et la matrice des corrélations 2 à 2).

Mais pour les hypothèses liées au terme d'erreur (H_2) et (H_3) , nous allons devoir être un peu malins !

et utiliser les outils à notre disposition, en particulier les **graphes de résidus**.

Hypothèses liées au **terme d'erreur**

L'inférence statistique relative à la régression (estimation des coefficients, tests d'hypothèses, etc.) repose principalement sur les hypothèses liées au **terme d'erreur** ε ,

qui résume les informations absentes du modèle :

- ▶ (H_2) les erreurs $(\varepsilon_i)_{i=1,\dots,n}$ sont centrées, de même variance et non corrélées entre elles ;
- ▶ (H_3) les erreurs ont une distribution symétrique, et plus précisément suivent une loi normale.

Graphes des résidus

- Pour inspecter ces hypothèses, nous disposons des **résidus estimés** produits par la différence entre les valeurs observées y_i et les prédictions ponctuelles de la régression $\hat{y}_i$:

$$\hat{\varepsilon}_i = y_i - \hat{y}_i$$

- Remarque : Dans un modèle avec constante, la moyenne des résidus est par construction égale à 0. Ce résultat ne préjuge donc en rien de la pertinence de la régression !

Démonstration

Le vecteur de résidus e est toujours orthogonal aux variables explicatives, c'est-à-dire :

$$e^T X = 0$$

Or, dans un modèle avec constante, si l'on choisit le vecteur $\lambda = (1, 0, \dots, 0)$, alors :

$$X\lambda = 1_n$$

On obtient donc :

$$e^T 1_n = e^T X\lambda = 0^T \lambda = 0$$

Un graphe des résidus “normal”

Aussi simpliste qu'il puisse paraître, le **diagnostic graphique** est un outil puissant pour **valider un modèle de régression linéaire**.

⇒ Il fournit un nombre important d'informations que les indicateurs statistiques appréhendent mal.

Toute analyse de régression doit être immédiatement suivie des **graphiques des résidus observés** (car il y en a plusieurs) :

- ▶ Les résidus sont toujours portés en ordonnée.
- ▶ Le type du graphique dépend de l'information que nous portons en abscisse.


Un graphe des résidus “normal”

Avant d'énumérer les différents types de graphiques, donnons quelques **principes généraux**, qui sont attendus pour un modèle valide :

- ▶ Les points doivent être uniformément répartis sur l'ordonnée
- ▶ On ne doit pas voir apparaître une forme de régularité dans le nuage de points
- ▶ Aucun point ne doit se démarquer ostensiblement des autres

Un graphe des résidus “normal”

Exemple de graphe des résidus attendu (qui ne contredit pas les hypothèses) :



Un graphe des résidus “normal”

```
summary(reg0)
```

```
##
## Call:
## lm(formula = data0$y ~ data0$x1 + data0$x2 + data0$x3)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.98761 -0.63289 -0.07845  0.69442  2.07901
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.002461   0.094537   0.026   0.979
## data0$x1      3.121550   0.096861  32.227 <2e-16 ***
## data0$x2     -2.070488   0.081720 -25.336 <2e-16 ***
## data0$x3      0.910697   0.087313  10.430 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9374 on 96 degrees of freedom
## Multiple R-squared:  0.9491, Adjusted R-squared:  0.9475
## F-statistic: 596.9 on 3 and 96 DF,  p-value: < 2.2e-16
```

Les différents graphes de résidus (1/2)

1. Graphe des résidus observés $\hat{\varepsilon}_i$ en fonction de la réponse Y

- Les résidus observés $\hat{\varepsilon}_i$ doivent être répartis aléatoirement autour de la valeur 0.
- Ils ne doivent pas avoir tendance à prendre des valeurs différentes selon les valeurs de Y

2. Graphe des résidus observés $\hat{\varepsilon}_i$ en fonction de chaque variable explicatives X_i

- L'idée est de détecter s'il y a une relation quelconque entre le terme d'erreur et les variables explicatives.
- Rappelons que les variables explicatives et les erreurs sont indépendantes par hypothèse (covariance nulle), cela doit être confirmé visuellement.

Les différents graphes de résidus (2/2)

3. Graphe des résidus observés $\hat{\varepsilon}_i$ en fonction du temps (pour des données temporelles)


- Dans le cas particulier des séries temporelles, nous pouvons produire un graphique supplémentaire en portant en abscisse la variable temps. Elle permet d'ordonner les valeurs d'une autre manière.
- Il est alors possible de détecter une rupture de structure associée à une date particulière (ex. guerre, crise politique, choc économique, etc.), à une corrélation entre point de temps successifs (auto-corrélations) , ... (voir UE Analyse de données temporelles au S2)

Exemples de situations qui 'compromettent' le modèle

- ▶ Asymétrie des résidus
- ▶ Résidus en "blocs"
- ▶ Hétéroscédasticité
- ▶ (Auto-corrélation des résidus, pour des données temporelles)

Asymétrie des résidus : Nuage de points (x1, résidus)


Exemple de distribution des résidus asymétrique en fonction de la variable à expliquer :



Asymétrie des résidus : densité empirique

Exemple de distribution des résidus asymétrique :

```
hist(reg1$residuals)
```



Asymétrie des résidus

Pourtant la sortie `summary()` semble convaincante :

```
summary(reg1)
```

```
##
## Call:
## lm(formula = y ~ x1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.035 -2.523 -1.166  2.354 10.135
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -65.439036   1.564834  -41.82  <2e-16 ***
## x1           0.734007   0.008808   83.34  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.707 on 398 degrees of freedom
## Multiple R-squared:  0.9458, Adjusted R-squared:  0.9457
## F-statistic: 6945 on 1 and 398 DF, p-value: < 2.2e-16
```

Asymétrie des résidus

L'asymétrie des résidus est notamment signe que la distribution des résidus ne suit pas une loi normale.

Cette situation survient lorsque certaines observations se démarquent des autres : elles sont alors souvent mal reconstituées par la régression.

(La moyenne des résidus est mécaniquement égale à 0, mais la dispersion est très inégale de part et d'autre de cette valeur.)

Asymétrie des résidus

Diagnostic

Il se peut alors que :

- ▶ les données soient en réalité formées par plusieurs populations.

(Exemple : en médecine, effectuer une régression en mélangeant les tranches d'âges).

- ▶ on se trouve face à un problème de spécification du modèle, par exemple une variable explicative importante manque.


Solutions possibles

- ▶ Chercher à mieux comprendre ce qui discrimine les 2 groupes (analyse descriptive, échange avec les experts du domaine, ...) afin d'affiner le modèle (faire 2 modèles distincts, ajouter une variable, ...)

Résidus en “blocs”

Les résidus apparaissent en “blocs” au-dessus (prédiction sous-estimée) ou en-dessous (prédiction sur-estimée) de la valeur 0.

Exemple de graphe des résidus en fonction d'une variable explicative X_1 pour lequel la relation à modéliser est non-linéaire :



Résidus en “blocs”

Pourtant la sortie `summary()` semble convaincante :

```
summary(reg2)
```

```
##
## Call:
## lm(formula = y ~ x1 + x2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.8312 -0.9495 -0.1329  0.6621  6.0766
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.83167    0.09946  28.472 < 2e-16 ***
## x1           3.10519    0.10194  30.461 < 2e-16 ***
## x2           0.35539    0.10560   3.365 0.000919 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.405 on 197 degrees of freedom
## Multiple R-squared:  0.825, Adjusted R-squared:  0.8232
## F-statistic: 464.4 on 2 and 197 DF, p-value: < 2.2e-16
```

Résidus en “blocs”

Diagnostic

- ▶ Cette situation survient si la relation étudiée est en réalité **non-linéaire**.
- ▶ La relation ne doit pas être modélisée à l'aide de la régression linéaire multiple.


Solutions possibles

- ▶ On peut y remédier en ajoutant une variable transformée dans le modèle (par ex. en passant une des variables au carré, ou en utilisant une transformation logarithmique, etc ...).
- ▶ On peut aussi considérer une régression non-linéaire (Ex.: arbres de régression, forêts aléatoires, réseaux de neurones, ...)

Hétéroscédasticité

Souvent associée à une des variables explicatives en abscisse, ce type de graphique indique que la variance des résidus n'est pas constante.

Ex sur ce graphe des résidus en fonction d'une variable explicative :



Hétéroscédasticité

Ici le R^2 est très mauvais :

```
summary(reg3)
```

```
##
## Call:
## lm(formula = y ~ x1 + x2 + x3)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -18.1190  -3.5263   0.0382   3.5417  17.5818
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.5476     0.4726   5.390 2.01e-07 ***
## x1             3.2973     0.4410   7.477 2.47e-12 ***
## x2            -1.7968     0.4846  -3.708 0.000272 ***
## x3             1.1266     0.4782   2.356 0.019475 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.652 on 196 degrees of freedom
## Multiple R-squared:  0.289, Adjusted R-squared:  0.2781
## F-statistic: 26.56 on 3 and 196 DF, p-value: 1.856e-14
```

Hétéroscédasticité

Diagnostic

- ▶ Il peut manquer une variable explicative.
- ▶ Cela peut également être lié au lien entre Y et une variable explicative (cas de non-linéarité).

Solutions possibles

- ▶ Consulter les experts du domaine d'étude, et considérer d'inclure de nouvelles variables.
- ▶ Ajouter une variable transformée dans le modèle (cf. cas de non-linéarité)

Auto-corrélation des résidus (données temporelles)

Ce problème est spécifique aux données longitudinales (mesurées sur des temps successifs).

Diagnostic

L'auto-corrélation peut être

- ▶ positive : des “blocs” de résidus sont positifs ou négatifs (figure gauche)
- ▶ négative : les résidus sont alternativement positifs et négatifs (figure droite).

Solutions possibles

- ▶ Essayer de détecter si les erreurs suivent un processus particulier au cours du temps à partir du graphe des résidus en fonction du temps. . . (voir UE analyse de données temporelles au S2)

Quand n est grand

Pour un grand jeu de données (n grand), le nuage de point peut être difficile à interpréter (superposition des points, difficile d'observer la densité)

2 solutions :

- ▶ Ajuster une estimation non linéaire (fonctions `ksmooth()`, `lowess()`)
- ▶ Réaliser un histogramme des résidus (fonction `hist()`)

8.4 Graphes des résidus partiels

Motivation

Il est souvent intéressant d'analyser le lien réel entre Y et une variable explicative X_j . Or l'approche intuitive qui consiste à étudier visuellement le nuage de points $(x_{i,j}, y_i)$ n'est pas fiable.

- ▶ En effet, toutes les autres variables explicatives peuvent aussi influencer les valeurs de Y et ainsi brouiller notre impression.
- ▶ C'est pourquoi, on cherche à mesurer le lien entre X_j et Y , **conditionnellement aux autres variables**.

Graphes des résidus partiels

Résidus partiels Soit la variable explicative X_j , le résidu partiel associé à la variable X_j pour l'individu i :

$$\begin{aligned}\hat{\varepsilon}_{j,i}^{\Delta} &= \hat{\beta}_j x_{j,i} + \hat{\varepsilon}_i \\ &= y_i - (\hat{\beta}_1 x_{1,i} + \dots + \hat{\beta}_{j-1} x_{j-1,i} + \hat{\beta}_{j+1} x_{j+1,i} + \dots + \hat{\beta}_p x_{p,i})\end{aligned}$$

- ▶ L'intérêt des résidus partiels est d'enlever l'effet estimé de toutes les variables explicatives autres que X_j sur Y .
- ▶ Cela est particulièrement utile dans la recherche de non-linéarité par exemple.

Graphes des résidus partiels

Ainsi, la nature de la liaison existante entre X_j et Y se représente avec le **nuage de points** : $(x_{j,i}, \hat{\varepsilon}_{j,i}^\Delta)_{1 \leq i \leq n}$

- ▶ S'il peut s'ajuster simplement par une **droite**, alors la liaison entre X_j et Y est **linéaire**.
- ▶ Les autres cas traduisent une liaison **non-linéaire** entre X_j et Y .

Il est intéressant de considérer une **transformation de X_j** qui correspond à l'équation de la courbe qui ajuste au mieux le nuage :

- ▶ soit pour remplacer la variable X_k dans le modèle par la transformation $g(X_j)$
- ▶ soit pour l'ajouter au modèle.

Les transformations les plus courantes sont les polynômes (x^2 , x^3 , ...) et les fonctions usuelles ($\exp()$, $\ln()$, ...).

Q-Q plot

- ▶ En statistique, le graphique Quantile-Quantile ou **Q-Q plot** est un outil graphique permettant d'évaluer la pertinence de l'ajustement d'une distribution donnée à un modèle théorique.
- ▶ Le terme de quantile-quantile provient du fait que l'on compare la **position de certains quantiles dans la population observée** avec leur **position dans la population théorique**.


Q-Q plot

```
# échantillon d'une loi gaussienne :
```

```
x=rnorm(100,10,5)
```


```
# qq plot
```

```
qqnorm(x,ylab = "Simulated normal distribution")
```



Q-Q plot

```
# échantillon d'une loi exponentielle :  
##qqplot  
x=rexp(100,1)  
qqnorm(x,ylab = "Simulated exponential distribution")
```



Q-Q plot

- ▶ En régression, on réalise en général un Q-Q plot des résidus de la régression. Ce graphique permet de se faire une idée de la normalité des résidus de la régression.

En résumé

Les différentes figures à examiner sont :

- ▶ Résidus $\hat{\varepsilon}$ vs variable à expliquer y
- ▶ Résidus $\hat{\varepsilon}$ vs chaque variable explicative x_i ,
- ▶ Histogramme des résidus $\hat{\varepsilon}$

Un bon graphe de résidus est un graphe sans structure apparente :

- ▶ Les résidus sont non structurés.
- Leur variance est constante.
- Ils sont indépendants des observations (x et y).
- ▶ Leur distribution est symétrique
 - ▶ Il n'y a pas de point influents... (section suivante)

8.5 Identifier les observations influentes

- ▶ Le critère des moindres carrés peut être très sensible à des **observations hors norme** c'est-à-dire qui présentent des valeurs trop singulières.
- ▶ L'étude descriptive initiale permet sans doute déjà d'en repérer mais c'est insuffisant.
- ▶ Un diagnostic doit être établi dans le cadre spécifique du modèle recherché afin d'identifier les **observations influentes**, c'est-à-dire celles dont une faible variation des variables explicatives et réponse (couple (x_i, y_i) dans le cas de régression linéaire simple) induisent une modification importante des caractéristiques du modèle.

Points atypiques (ou aberrants)

- ▶ Par définition, un point **atypique ou aberrant** est une observation qui s'écarte résolument des autres.
- ▶ Causes :
 - Cela peut être dû à une erreur de recueil des données.
 - Cela peut aussi correspondre à un individu qui n'appartient pas à la population étudiée.
 - Un point peut paraître atypique “par hasard” en raison de la variabilité de l'échantillonnage, en particulier si n est petit.
- ▶ Attention, **un point atypique n'est pas forcément influent!**

Points influents


Les points **influents** sont des observations qui **pèsent exagérément** sur les résultats de la régression.

On peut les distinguer de plusieurs manières :

- ▶ ils sont “isolés” des autres points (en cela ils se rapprochent des points atypiques)
- ▶ ils correspondent à des **valeurs extrêmes des variables explicatives** (éloignés du barycentre $\bar{x}$)
- ▶ Attention, leurs résidus ne sont pas forcément plus élevés que les autres.

Exemple de point potentiellement influent

Ici, le point ayant la valeur y la plus élevée est mal reconstitué par la régression (le résidu est élevé).



Point atypique ou influent ?

Bien souvent la distinction entre les points atypiques et les points influents est difficile : **un point peut être atypique sans être influent**

Notez bien :

- ▶ Cela est difficilement discernable dans un graphique des résidus.
- ▶ Une manière sûre de le circonscrire est de **recalculer les coefficients de la régression en écartant le point** : si les résultats diffèrent significativement, en termes de prédiction ou terme de différence entre les coefficients estimés, alors le point est influent.
- ▶ Il est plus approprié de passer par le calcul de **critères dédiés**

Erreur de test $\hat{\varepsilon}_{(-i)i}$

- ▶ Chaque observation i peut être utilisée simultanément pour évaluer la capacité prédiction du modèle.
- ▶ Dans ce cas, on mesure l'**erreur de test** :

→ Construction de l'échantillon $(x_{(-i)}, y_{(-i)})$ de taille $n - 1$ (on retire la i ème observation (x_i, y_i))

→ Estimation de $\hat{\beta}_{(-i)}$ à partir de cet échantillon $(x_{(-i)}, y_{(-i)})$

→ Calcul de la prédiction :

$$\hat{y}_{(-i)i} = \hat{\beta}_{(-i)0} + x_{i1}\hat{\beta}_{(-i)1} + \dots + x_{ip}\hat{\beta}_{(-i)p}$$

- ▶ On obtient alors l'erreur de test pour l'observation i :

$$\hat{\varepsilon}_{(-i)i} = y_i - \hat{y}_{(-i)i}$$

et on note $\hat{\sigma}_{(-i)}^2 = \frac{\|\hat{\varepsilon}_{(-i)}\|^2}{n-1}$ la variance estimée des erreurs en réalisant une régression **sans l'individu i** .

Erreur de test $\hat{\varepsilon}_{(-i)i}$

Faut-il calculer n modèles ? (afin d'écarter successivement chaque observation $1, 2, \dots, i, \dots, n$)

=> **NON !** On peut montrer que :

$$\hat{\varepsilon}_{(-i)i} = \frac{\hat{\varepsilon}_i}{1 - h_{ii}}$$

Critères

Il existe de nombreux critères pour détecter des observations **potentiellement** influentes, notamment :

- ▶ Effet levier
- ▶ Taille des résidus studentisés
- ▶ Distance de Cook (Critère synthétique des 2 précédents)

Leviers h_{ii} (et matrice de projection orthogonale $P_X = H$)

On a vu que les valeurs ajustées peuvent s'écrire comme la projection du vecteur Y sur le sous-espace engendré par les colonnes de la matrice X , ce qui s'écrit :

$$\hat{Y} = X(X^T X)^{-1} X^T Y = P_X Y = H Y$$

La matrice de projection orthogonale P_X est aussi appelée '**Hat-matrix**' ('matrice chapeau'), et notée H , car c'est un opérateur qui permet de passer de Y aux valeurs prédites $\hat{Y}$ de Y .

Leviers h_{ii} (et matrice de projection orthogonale $P_X = H$)

- ▶ P_X est une matrice idempotente, i.e. $P_X \circ P_X = P_X$

(car la projection du projeté orthogonal $\hat{Y}$ sur le sev engendré par les colonnes de X est lui-même)

- ▶ P_X est une matrice symétrique.

Demo :

$$(X(X^T X)^{-1} X^T)^T = (X^T)^T (X(X^T X)^{-1})^T = X((X^T X)^{-1})^T X^T$$

or $(X^T X)$ est symétrique, donc sa matrice inverse est symétrique également.

On obtient donc $(X(X^T X)^{-1} X^T)^T = X(X^T X)^{-1} X^T$.

Leviers h_{ii} (et matrice de projection orthogonale P_X)

- ▶ D'après les propriétés (idempotente et symétrique) de la matrice de projection orthogonale P_X , on a :

$$\begin{aligned}V(\hat{Y}) &= V(P_X Y) = P_X V(Y) P_X^T = P_X I_n \sigma^2 P_X^T = \sigma^2 P_X P_X^T \\&= \sigma^2 P_X P_X = \sigma^2 P_X\end{aligned}$$

- ▶ En notant h_{ii} la composante correspondant à la i -ème ligne et la i -ème colonne de $P_X = H$, on a :

$$V(\hat{Y}_i) = h_{ii} \sigma^2$$

- ▶ La valeur h_{ii} est appelée le **levier** de l'observation i : plus h_{ii} est élevé, plus y_i contribuera à la prédiction $\hat{y}_i$.

Leviers h_{ij}

- **Propriété :** $\forall 1 \leq i \leq n, 0 \leq h_{ii} \leq 1$

Démo : Les valeurs propres des matrices idempotentes sont égales à 0 ou à 1. Aussi, pour tout vecteur normé u , on a $0 \leq u^T P_X u \leq 1$. En prenant un vecteur v composé de 0 et d'un seul 1 (en i ème composante), on obtient $v^T P_X v = h_{ii}$, ce qui implique : $0 \leq h_{ii} \leq 1$.

- **Propriété :** $\sum_{i=1}^n h_{ii} = p + 1$

Démo : La trace d'une matrice idempotente est égale à son rang, donc la trace de P_X vaut $p + 1$. On obtient alors : $\sum_{i=1}^n h_{ii} = \text{tr}(P_X) = p + 1$.

- En pratique, un individu ayant une valeur de $h_{ii} > \frac{p+1}{n}$ a donc un levier important. Plus précisément, on dit en général, que i **est un point levier si**

$$h_{ii} > 2 \left(\frac{p+1}{n} \right)$$

Résidus standardisés

- Le vecteur des **résidus observés** s'écrivent comme la projection du vecteur Y sur l'orthogonal du sous-espace engendré par les colonnes de la matrice X :

$$\hat{\varepsilon} = (\hat{\varepsilon}_i)_{1 \leq i \leq n} = Y - \hat{Y} = (I_n - P_X)Y$$

- La variance de $\hat{\varepsilon}$ est donc :

$$\begin{aligned} V(\hat{\varepsilon}) &= V[(I_n - P_X)Y] = (I_n - P_X)V(Y)(I_n - P_X)^T \\ &= (I_n - P_X)I_n\sigma^2(I_n - P_X) = \sigma^2(I_n - P_X) \end{aligned}$$

soit, pour tout $i = 1 \dots n$,

$$V(\hat{\varepsilon}_i) = (1 - h_{ii})\sigma^2$$

Résidus standardisés

- ▶ Contrairement aux termes d'erreurs ε_i , les résidus observés $\hat{\varepsilon}_i$ ne sont pas homoscedastiques (de même variance). Afin de les rendre comparables, il est donc d'usage de calculer les **résidus standardisés** (chacun est divisé par l'estimation de son écart-type) :

$$r_i = \frac{\hat{\varepsilon}_i}{\sqrt{\hat{\sigma}^2(1 - h_{ii})}}$$

- ▶ Les résidus standardisés sont obtenus avec la fonction `rstandard()`.

Résidus studentisés

- ▶ La statistique r_i a cependant un problème : $\hat{\varepsilon}_i$ n'est pas indépendant de $\hat{\sigma}$. Il n'est donc pas possible de déduire la distribution de probabilité des r_i . On préférera calculer des **résidus studentisés** définis par :

$$t_i = \frac{\hat{\varepsilon}_i}{\sqrt{\hat{\sigma}_{(-i)}^2(1 - h_{ii})}}$$

où $\hat{\sigma}_{(-i)}^2$ est la variance estimée des erreurs en réalisant une régression **sans l'individu i**.

- ▶ En procédant ainsi, le numérateur et le dénominateur de t_i sont indépendants. Sous l'hypothèse de normalité (H_3), les résidus studentisés t_i ont donc une distribution de Student à $n - p - 2$ degrés de liberté.

(Question : pourquoi $(n - p - 2)$ et non $(n - p - 1)$?)

Résidus studentisés

- ▶ Les résidus studentisés peuvent également être obtenus à partir des résidus standardisés r_i :

$$t_i = r_i \sqrt{\frac{n - p - 2}{n - p - 1 - r_i^2}}$$

- ▶ De trop grands résidus sont des signaux d'alerte. En pratique, on considère grand un résidu studentisé de valeur absolue supérieure quantile d'ordre 97,5% d'une loi de Student à $(n - p - 2)$ degrés de liberté :

$$|t_i| > qt(0.975, df = n - p - 2)$$

Ce quantile est obtenu sous R par la fonction `qt(0.975, df = n-p-2)` ($\Rightarrow$ valeur proche de 2).

- ▶ Les résidus studentisés sont obtenus avec la fonction `rstudent()`.

Mesure d'influence

Les deux critères précédents (effet levier et taille des résidus studentisés) contribuent à déceler des observations

potentiellement influentes :

- ▶ L'effet levier peut apparaître pour des observations dont les valeurs prises par les variables explicatives sont élevées (observations loin du barycentre $\bar{x}$).
- ▶ De grands résidus signalent plutôt des valeurs atypiques de la variable à expliquer.

Ces informations sont résumées dans des **critères synthétiques** évaluant directement l'influence d'une observation sur certains paramètres : les prédictions $\hat{Y}$, les paramètres $\hat{\beta}_0, \hat{\beta}_1$, ... (Remarque : Tous ces indicateurs proposent de **comparer** un paramètre estimé **sans la i ème observation** et ce même paramètre estimé **avec toutes les observations**.)

=> Un des critères couramment utilisés est la **Distance de Cook**.

Distance de Cook

- ▶ La **distance de Cook** est un indice calculable pour chaque observation i , qui permet de mesurer l'influence de cette observation sur l'estimation du coefficient β .
- ▶ Pour bâtir une telle mesure, nous considérons la distance entre le coefficient estimé $\hat{\beta}$ et le coefficient $\hat{\beta}_{(-i)}$ que l'on estime en enlevant l'observation i .
- ▶ Pour tout $i = 1 \dots n$:

$$\begin{aligned} D_i &= \frac{1}{(p+1)\hat{\sigma}^2} (X\hat{\beta} - X\hat{\beta}_{(-i)})^T (X\hat{\beta} - X\hat{\beta}_{(-i)}) \\ &= \frac{(\hat{Y} - \hat{Y}_{(-i)})^T (\hat{Y} - \hat{Y}_{(-i)})}{(p+1)\hat{\sigma}^2} = \frac{\sum_{j=1}^n (\hat{y}_j - \hat{y}_{j(-i)})^2}{(p+1)\hat{\sigma}^2} \end{aligned}$$

Distance de Cook

- On peut montrer que la distance de Cook s'écrit comme une fonction des leviers et des résidus :

$$D_i = \frac{h_{ii}}{(p+1)(1-h_{ii})^2} \frac{\hat{\varepsilon}_i^2}{\hat{\sigma}^2}$$

$$D_i = \frac{h_{ii}}{(p+1)(1-h_{ii})} r_i^2$$

où r_i est le résidu standardisé.

- La distance de Cook mesure ainsi l'influence d'une observation sur l'ensemble des prévisions **en prenant en compte effet levier ET importance des résidus**.

Distance de Cook

- ▶ Une forte valeur de D_i indique que la i ème observation est influente. La suppression de cette observation peut entraîner de grosses modifications sur l'équation de la régression.
- ▶ La fonction R permettant de calculer les distances de Cook est `cooks.distance()`.

En résumé

- ▶ **Observation aberrante** : résidu studentisé t_i élevé.

=> Interprétation : l'observation ne provient pas de la même population, et ne suit pas le même modèle.

- ▶ **Point levier** : poids h_i élevé.

=> Interprétation : variables explicatives x_i éloignées des autres, peut quand même faire partie de la population (variabilité de l'échantillonnage)

- ▶ **Observation influente** : distance de Cook D_i élevée

=> Interprétation : combinaison des 2 critères point levier et obs. aberrante.

Détection des points influents

La stratégie de détection consiste le plus souvent à :

- ▶ repérer les points influents **en comparant les distances de Cook avec la valeur 1**,
- ▶ puis à **expliquer cette influence** en considérant, pour ces observations, leur résidu studentisé ainsi que leur effet levier.

Que faire des observations influentes ?

Une fois les observations influentes repérées, il n'y a pas de remède universel :

- ▶ supprimer une valeur influente (Attention, cela peut rendre influentes de nouvelles observations),
- ▶ corriger une erreur de mesure,
- ▶ construire une estimation robuste
- ▶ ne rien faire
- ▶ ...

La décision dépend du contexte et doit être argumentée.

8.6 EN BREF (Validation du modèle linéaire)

1. Etude des colinéarité des variables explicatives
2. Contrôle de l'ajustement du modèle

1) Etude des colinéarité des variables explicatives

L'estimation des paramètres et de leurs variances nécessite le calcul de l'inverse de la matrice $X^T X$. On dit que $X^T X$ est mal conditionnée si son déterminant est proche de 0. Cette situation se produit lorsque les variables explicatives sont très corrélées entre-elles. On parle alors de multi-colinéarité et cela conduit à des estimations biaisées des paramètres avec des variances importantes.

Pour se faire un idée sur ces questions, on peut étudier :

- ▶ matrice X de plein rang
- ▶ conditionnement de la matrice $X^T X$
- ▶ calcul du VIF pour chaque variable explicative

2) Contrôle de l'ajustement du modèle (1/2)

Une fois le modèle mis en oeuvre, on doit vérifier a posteriori le “bien-fondé statistique” de ce modèle du point de vue de l'adéquation de la valeur ajustée $\hat{y}_i$ à la valeur observée y_i , de l'absence de structure des résidus et de l'absence de données aberrantes ou influentes.

Pour se faire une idée sur ces questions, on peut étudier :

- ▶ le graphe des n points $(y_i, \hat{y}_i)$ qui “doivent” être à peu près alignés selon la droite de pente 1.
- ▶ le graphe des n points $(\hat{y}_i, \hat{\varepsilon}_i)$ qui doit correspondre à celui de deux variables non-corrélées.
- ▶ les graphes ou histogrammes des résidus et résidus partiels en fonction de chaque variable explicative, qui doivent être sans structure apparentes (détection de non-linéarité, hétéroscédasticité, présence de plusieurs populations, ...)

($\Rightarrow$ considérer les résidus standardisés r_i ou studentisés t_i)

2) Contrôle de l'ajustement du modèle (2/2)

- ▶ Q-Q plot des résidus studentisés pour comparer leur répartition à la distribution $\mathcal{N}(0, 1)$ (tout en étant conscient que les n résidus ne sont pas indépendants)
- ▶ Identifier les résidus studentisés élevés. De grands résidus signalent plutôt des valeurs atypiques de la variable à expliquer.
- ▶ Identifier les effets levier élevés par les éléments diagonaux de la matrice H . L'effet levier apparaît principalement pour des observations dont les valeurs prises par les variables explicatives sont éloignées de la moyenne.
- ▶ Identifier les observations influentes avec la distance de Cook D_i

Conclusion

A cette étape, on doit avoir un jeu de données propre pour le modèle linéaire :

- ▶ pas de multi-colinéarité dans la matrice X
- ▶ relations linéaires entre variables explicatives et variable à expliquer
- ▶ résidus “sans structure”
- ▶ pas d'observation aberrante ou trop influente

Il reste à sélectionner un modèle et à l'interpréter !

8.7 Quelques packages R bien utiles

Package **ggglm**

```
install.packages('ggglm')  
library(ggglm)  
model<-lm(y~x)  
ggglm(model)
```

Package ggplot2

```
install.packages('ggplot2')  
library(ggplot2)
```

La fonction `ggplot()` vous permet de représenter graphiquement toutes les fonctions `stat_*()` : `stat_normal_qq()`, `stat_fitted_resid()`, `stat_resid_hist()`, `stat_scale_location()`, `stat_cooks_leverage()`, `stat_cooks_obs()`, and `stat_resid_leverage()`

```
ggplot(data = model) +  
  stat_fitted_resid()
```

```
ggplot(data = model) +  
  stat_fitted_resid() +  
  theme_minimal()
```

Package **car**

```
install.packages('car')  
library(car)  
?vif  
?qqPlot  
?leveragePlots  
?influencePlot  
?crPlots
```

Voici un tutoriel dédié au diagnostic de modèle de régression avec le package R 'car':

<https://www.statmethods.net/stats/riagnostics.html>

Pour aller plus loin

- Interprétation et mesure d'importance :

Interpretable Machine Learning. A Guide for Making Black Box Models Explainable

Christoph Molnar

2024-07-31

Livre : <https://christophm.github.io/interpretable-ml-book/>

Modèle linéaire :

<https://christophm.github.io/interpretable-ml-book/limo.html>

GLM, GAM et plus : <https://christophm.github.io/interpretable-ml-book/extend-lm.html>