

Modèles de régression linéaire et outils du diagnostic (suite)

S. Lèbre

9. Choix de modèle

De façon un peu schématique, on peut associer la pratique de la modélisation statistique à trois objectifs, qui peuvent éventuellement être poursuivis en complémentarité :

- ▶ Objectif descriptif
- ▶ Objectif explicatif
- ▶ Objectif prédictif

Objectif descriptif

- ▶ Il vise à rechercher de façon exploratoire les liaisons entre Y et d'autres variables, potentiellement explicatives, X_j qui peuvent être nombreuses afin, par exemple d'en sélectionner un sous-ensemble.
- ▶ A cette stratégie, à laquelle peuvent contribuer des Analyses en Composantes Principales, correspondent des algorithmes de recherche (pas à pas) moins performants mais économiques en temps de calcul si p est grand.
- ▶ Attention, si n est petit, et la recherche suffisamment longue avec beaucoup de variables explicatives, il sera toujours possible de trouver un 'bon' modèle expliquant y . (C'est l'effet data mining dans les modèles économétriques, appelé maintenant data snooping)

Objectif explicatif

- ▶ L'objectif explicatif est sous-tendu par une connaissance *a priori* du domaine concerné et dont des résultats théoriques peuvent vouloir être confirmés, infirmés ou précisés par l'estimation des paramètres.
- ▶ Le modèle doit être **interprétable**.
- ▶ Dans ce cas, les résultats inférentiels précédents permettent de construire le bon test conduisant à la prise de décision recherchée.

Objectif prédictif

- ▶ Dans un objectif prédictif, l'accent est mis sur la qualité des prévisions. C'est la situation rencontrée en **apprentissage statistique**. Ceci conduit à rechercher des modèles **parcimonieux** c'est-à-dire avec un nombre volontairement restreint de variables explicatives pour réduire la variance de $\hat{Y}$.
- ▶ Le modèle ainsi obtenu peut favoriser des estimateurs biaisés au profit d'une variance plus faible (même si le théorème de Gauss-Markov (cf. section 4.1 Propriétés de l'estimateur $\hat{\beta}$) indique que, parmi les estimateurs sans biais, celui des moindres carrés est de variance minimum). Tout est affaire de **compromis entre biais et variance** !
- ▶ Un bon modèle n'est donc plus celui qui explique le mieux les données au sens d'un R^2 maximum (au prix d'un nombre important de variables pouvant introduire des colinéarités) mais celui conduisant aux **prévisions les plus fiables**.

Illustration : Compromis Biais/Variance

- ▶ Les figures suivantes représentent un jeu de données simulées sur lesquelles des polynômes de degrés croissants sont ajustés.
- ▶ L'ajustement du modèle mesuré par le R^2 croît logiquement avec le nombre de paramètres et atteint la valeur 1 lorsque le polynôme interpole les observations.
- ▶ Le R^2 ne peut-être un bon critère de sélection de modèles ; il ne peut servir qu'à comparer des modèles de même dimension car sinon conduit à sélectionner le modèle le plus complexe, c'est-à-dire celui correspond au plus grand espace de projection, et conduit donc au sur-ajustement.

Illustration : Compromis Biais/Variance




Figure 1: Régression linéaire (à gauche) et polynomiale de degré 3 (à droite).

Illustration : Compromis Biais/Variance




Figure 2: Régression polynomiale de degré 5 (à gauche) et 10 (à droite).

Illustration : Compromis Biais/Variance


Il y a principalement deux façons de biaiser un modèle linéaire dans le but de restreindre la variance :

- ▶ en réduisant le nombre de variables explicatives et donc en simplifiant le modèle (**sélection de variables**, selon un critère donné ou pénalisation Lasso *i.e.* en norme l_1),
- ▶ en contraignant les paramètres du modèle, en les rétrécissant (shrinkage), par une régression ridge qui opère une **régularisation** par pénalisation en norme l_2 .

(Voir méthodes par pénalisation, ECUE : 'Régularisation et optimisation des modèles')

Compromis Biais/Variance

Dans les deux cas (Sélection de variables ou régularisation), une plus faible erreur de prédiction est attendue en ajustant le **compromis Biais/Variance** le modèle.



(Rappel) Solutions à la colinéarité entre prédicteurs ?

Nous avons vu que la colinéarité entre prédicteurs remet en question les hypothèses du modèle et rend l'estimation des coefficients difficile (cf section 8).

Sélection de variables

Si le vrai modèle sous-jacent ne contient que **peu de prédicteurs** réellement liés à la variable réponse, on peut vouloir **sélectionner** ceux ayant un grand pouvoir prédictif. On vise ainsi :

- ▶ de meilleures performances prédictives,
- ▶ une meilleure interprétabilité du modèle.

Régularisation

Attention, si plusieurs prédicteurs ont des effets similaires sur la réponse, la sélection de prédicteurs interprétables est très difficile (l'un peut remplacer l'autre, etc ...).

Une solution est de **régulariser** le problème en **contraignant** les paramètres β à se trouver dans un espace approprié, de sorte à rendre $X^T X$ inversible, et faciliter l'interprétabilité (cf. ECUE optimisation et régularisation).

Sélection de variables

Problématique

Lorsque l'on augmente le nombre de variables :

- ▶ on intègre de plus en plus d'information dans le modèle,
- ▶ on augmente le nombre de paramètres à estimer et la variance $V(\hat{Y}_i)$ augmente.

Sélection de variables

Problématique

Lorsque l'on augmente le nombre de variables :

- ▶ on intègre de plus en plus d'information dans le modèle,
- ▶ on augmente le nombre de paramètres à estimer et la variance $V(\hat{Y}_i)$ augmente.

Solution possible

On recherche un (petit) ensemble $\mathcal{S}$ de k variables parmi p telles que

$$Y \approx X_{\mathcal{S}}\beta_{\mathcal{S}}$$

Sélection de variables

Problématique

Lorsque l'on augmente le nombre de variables :

- ▶ on intègre de plus en plus d'information dans le modèle,
- ▶ on augmente le nombre de paramètres à estimer et la variance $V(\hat{Y}_i)$ augmente.

Solution possible

On recherche un (petit) ensemble $\mathcal{S}$ de k variables parmi p telles que

$$Y \approx X_{\mathcal{S}}\beta_{\mathcal{S}}$$

Mise en oeuvre

Pour trouver un compromis, on a besoin :

1. d'un **critère** pour évaluer la qualité du modèle;
2. d'un **algorithme** pour déterminer les k variables optimisant ce critère.

Sélection de variables

1. **Critères de comparaison de modèles**
2. Algorithmes de sélection de sous-ensembles

8.1 Critères de comparaison de modèles

On a déjà vu certains critères :

- ▶ Statistique du F de Fisher
- ▶ Coefficient de détermination $R^2 = \frac{SSR}{SST} \Rightarrow$ ne permet pas de comparer des modèles de dimension différente !!
- ▶ R^2 ajusté

A partir du vecteur des erreurs de test $\hat{\varepsilon}_{(-i)i}$, on peut calculer la somme des carrés de ces résidus, appelé le **PRESS de Allen** (Predicted Residual Sum of Squares) :

$$PRESS = \sum_{i=1}^n \hat{\varepsilon}_{(-i)i}^2$$

Voici également 3 critères pénalisés parmi les plus utilisés :

- ▶ Le C_p de Mallows
- ▶ Le critère d'information d'Akaike (AIC)
- ▶ Le critère d'information bayésien (BIC)

Critères pénalisés

Principe général

Plutôt que d'estimer l'erreur de prédiction par l'erreur de test, on estime de combien l'erreur d'entraînement sous-estime la vraie erreur.

Forme générique des critères

Sans ajuster d'autres modèles, on calcule

$$\hat{err} = ||\hat{\epsilon}||^2 + \text{"optimisme"}$$

Remarques

- ▶ C'est beaucoup moins coûteux que la validation croisée
- ▶ Cela permet de pénaliser les modèles trop complexes.

Le C_p de Mallows

Définition

- ▶ La statistique du C_p de Mallows est définie par :

$$C_p = \frac{||\hat{\varepsilon}||^2}{\hat{\sigma}^2} - (n - 2(p + 1))$$

- ▶ Il y a un problème ! Nous ne pouvons pas estimer σ^2 par $\hat{\sigma}^2 = \frac{||\hat{\varepsilon}||^2}{n-p-1}$. **Pourquoi ?**

Le C_p de Mallows

Définition

- ▶ La statistique du C_p de Mallows est définie par :

$$C_p = \frac{||\hat{\varepsilon}||^2}{\hat{\sigma}^2} - (n - 2(p + 1))$$

- ▶ Il y a un problème ! Nous ne pouvons pas estimer σ^2 par $\hat{\sigma}^2 = \frac{||\hat{\varepsilon}||^2}{n-p-1}$. **Pourquoi ?**
- ▶ Solution : Nous estimons σ^2 par la somme des carrés des résidus du modèle faisant intervenir toutes les variables $(p + 1)$ explicatives à disposition.
 - ▶ Pour le modèle complet, qui a $(p + 1)$ paramètres, nous avons donc toujours : $C_p = p + 1$.
 - ▶ Et pour les autres ? Le C_p prendra d'autres valeurs que $p + 1$.

Le C_p de Mallows

- ▶ Il est d'usage de rechercher un modèle qui minimise le C_p tout en fournissant une valeur inférieure et proche de $(k + 1)$ pour un modèle avec k variables explicatives.
- ▶ Ceci revient à considérer que le modèle complet est moins fiable qu'un modèle réduit (ce dernier étant possiblement biaisé, mais d'estimation plus précise).

Critère d'information d'Akaike (AIC)

Le critère d'information AIC s'applique aux modèles estimés par une **méthode du maximum de vraisemblance** : les analyses de variance, les régressions linéaires multiples, les régressions logistiques et de Poisson peuvent rentrer dans ce cadre.

Définition

- Le critère AIC est défini par :

$$AIC = -2\log(L) + 2k$$

où L est la vraisemblance et k le nombre de paramètres libres dans le modèle.

- Avec ce critère, la déviance du modèle $-2\log(L)$ est pénalisée par 2 fois le nombre de paramètres libres.

Critère d'information d'Akaike (AIC)

Interprétation

- Le critère AIC représente donc un compromis entre la **qualité de l'ajustement** (vraisemblance) et la **complexité du modèle** en pénalisant les modèles ayant un grand nombre de paramètres, ce qui limite les effets de **sur-ajustement** (augmenter le nombre de paramètres améliore nécessairement la qualité de l'ajustement mais limite la valeur générale du modèle, et ainsi la capacité de prédiction).

Critère d'information bayésien *BIC*

Définition

Le critère *BIC* est défini par :

$$BIC = -2\log(L) + k \log(n)$$

où L est la vraisemblance, k le nombre de paramètres libres dans le modèle et n le nombre d'observations.

Interprétation

Il est plus parcimonieux que le critère *AIC* puisqu'il pénalise davantage le nombre de variables présentes dans le modèle.

8.2 Algorithmes de sélection de sous-ensembles

2 catégories de méthodes :

- ▶ Recherche exhaustive (best-subset)
- ▶ Sélection Pas à pas (stepwise : forward, backward, both)

Recherche exhaustive (best-subset)

Algorithme

Pour $k = 0 \dots p$, trouver le sous-ensemble de k variables qui donne la plus petite erreur $\|\hat{\varepsilon}\|^2$ (SCR) parmi les 2^k modèles.

Propriétés

- ▶ Peut être généralisé à d'autres critères (R^2 ajusté, AIC , BIC , ...)
- ▶ Existence d'un algorithme efficace ('**Leaps and Bound**')
- ▶ Attention, impossible pour p grand (dès que $p > 30$).

Sélection avant (Forward regression)

Algorithme

1. Commencer avec $\mathcal{S} = \emptyset$;
2. A l'étape k trouver la variable qui ajoutée à $\mathcal{S}$ donne le meilleur modèle
3. Répéter jusqu'au modèle à p variables

Propriétés

- ▶ permet d'identifier le meilleur modèle en terme de SCR ou R^2 ajusté, AIC , BIC , ...
- ▶ approprié lorsque p est grand
- ▶ biais important, mais variance/complexité contrôlée.
- ▶ algorithme dit **glouton** (greedy)

Sélection avant (Forward regression) **both**

Algorithme

1. Commencer avec $\mathcal{S} = \emptyset$;
2. A l'étape k trouver le meilleur modèle **lorsqu'une variable est ajoutée ou enlevée.**
3. Répéter jusqu'au modèle à p variables

Propriétés

- ▶ permet d'identifier le meilleur modèle en terme de SCR ou R^2 ajusté, AIC , BIC , ...
- ▶ approprié lorsque p est grand
- ▶ biais important, mais variance/complexité contrôlée.
- ▶ algorithme dit **glouton** (greedy)

Sélection arrière

Algorithme

1. Commencer avec le modèle plein $S = \{1, \dots, p\}$.
2. A l'étape k , enlever la variable ayant le moins d'influence sur l'ajustement.
3. Répéter jusqu'au modèle nul.

Propriétés

- ▶ le meilleur modèle est compris en terme de SCR ou R^2 ajusté, AIC , BIC , ...
- ▶ ne fonctionne pas si $n < p$
- ▶ algorithme dit '**glouton**' (greedy)

Recherche exhaustive (fonction regsubsets() du package leaps)

Données cancer de la prostate

```
load("../../../Data/Prostate.rda")  
dim(Prostate)
```

```
## [1] 97  9
```

Statistique descriptive des données

Validation du modèle linéaire (voir TP3)

Recherche exhaustive (SCR)

```
library(leaps)
```

On calcule tous les modèles possibles :


```
out <- regsubsets(lpsa ~ . , data=Prostate,  
                 nbest=100, really.big=TRUE)  
bss <- summary(out)
```

Extraction de la taille et des valeurs de SCR + le modèle nul (seulement la constante)
:


```
bss.size <- as.numeric(rownames(bss$which))  
intercept <- lm(lpsa ~ 1, data=Prostate)  
bss.best.rss <-  
c(sum(resid(intercept)^2), tapply(bss$rss, bss.size, min))
```

```
plot(0:8, bss.best.rss, ylim=c(30, 135), type="b", xlab="subset size",  
     ylab="RSS", col="red2" )  
points(bss.size, bss$rss, pch=20, col="gray", cex=0.7)
```


Recherche exhaustive (SCR)




Recherche exhaustive C_p




Recherche exhaustive R^2



Recherche exhaustive R^2 Ajusté



Recherche exhaustive *BIC*



Recherche Pas à pas (fonction step()) du package MASS)

Création du modèle nul et du modèle plein

```
null <- lm(lpsa ~ 1, data=Prostate)
full <- lm(lpsa ~ ., data=Prostate)
```

Création de l'ensemble des modèles à parcourir (scope)

```
lower <- ~1
upper <- ~lcavol+lweight+age+lbph+svi+lcp+gleason+pgg45
scope <- list(lower=lower, upper=upper)
```

Stepwise avec AIC (forward, backward, both)

```
fwd <- step(null, scope, direction="forward", k=2, trace=TRUE)
```

```
## Start:  AIC=28.84
## lpsa ~ 1
##
##           Df Sum of Sq    RSS    AIC
## + lcavol   1     69.003  58.915 -44.366
## + svi      1     41.011  86.907  -6.658
## + lcp      1     38.528  89.389  -3.926
## + pgg45    1     22.814 105.103  11.783
## + gleason  1     17.416 110.502  16.641
## + lweight  1     16.041 111.877  17.841
## + lbph     1       4.136 123.782  27.650
## + age      1       3.679 124.239  28.007
## <none>          127.918  28.838
```

Forward regression (résultats)

```
fwd
```

```
##
```

```
## Call:
```

```
## lm(formula = lpsa ~ lcavol + lweight + svi + lbph + age, data = Prostate)
```

```
##
```

```
## Coefficients:
```

```
## (Intercept)      lcavol      lweight          svi          lbph          age  
##      0.95102      0.56561      0.42369      0.72096      0.11184     -0.01489
```

```
fwd$anova
```

##	Step	Df	Deviance	Resid. Df	Resid. Dev	AIC
## 1		NA	NA	96	127.91766	28.83755
## 2	+ lcavol	-1	69.0028744	95	58.91478	-44.36603
## 3	+ lweight	-1	5.9484273	94	52.96636	-52.69024
## 4	+ svi	-1	5.1813959	93	47.78496	-60.67600
## 5	+ lbph	-1	1.3000579	92	46.48490	-61.35159
## 6	+ age	-1	0.9592528	91	45.52565	-61.37420

Backward regression

```
bwd
```

```
##
```

```
## Call:
```

```
## lm(formula = lpsa ~ lcavol + lweight + age + lbph + svi, data = Prostate)
```

```
##
```

```
## Coefficients:
```

```
## (Intercept)      lcavol      lweight      age      lbph      svi  
##      0.95102      0.56561      0.42369     -0.01489      0.11184      0.72096
```

```
bwd$anova
```

```
##      Step Df    Deviance Resid. Df Resid. Dev      AIC  
## 1          NA         NA         88    44.16313 -58.32161  
## 2 - gleason   1 0.04123419         89    44.20436 -60.23109  
## 3   - lcp     1 0.66232990         90    44.86669 -60.78848  
## 4   - pgg45  1 0.65895836         91    45.52565 -61.37420
```

Stepwise regression

```
both
```

```
##
```

```
## Call:
```

```
## lm(formula = lpsa ~ lcavol + lweight + svi + lbph + age, data = Prostate)
```

```
##
```

```
## Coefficients:
```

```
## (Intercept)      lcavol      lweight          svi          lbph          age  
##      0.95102      0.56561      0.42369      0.72096      0.11184     -0.01489
```

```
both$anova
```

##		Step	Df	Deviance	Resid. Df	Resid. Dev	AIC
## 1			NA	NA	96	127.91766	28.83755
## 2	+	lcavol	-1	69.0028744	95	58.91478	-44.36603
## 3	+	lweight	-1	5.9484273	94	52.96636	-52.69024
## 4		+ svi	-1	5.1813959	93	47.78496	-60.67600
## 5		+ lbph	-1	1.3000579	92	46.48490	-61.35159
## 6		+ age	-1	0.9592528	91	45.52565	-61.37420

Stepwise regression

Modification pour utiliser le BIC ($k = \log(n)$)

```
BIC <- step(null, scope, k=log(n <- nrow(Prostate)), trace=TRUE)
```

```
## Start: AIC=31.41
```

```
## lpsa ~ 1
```

```
##
```

	Df	Sum of Sq	RSS	AIC
## + lcavol	1	69.003	58.915	-39.217
## + svi	1	41.011	86.907	-1.508
## + lcp	1	38.528	89.389	1.224
## + pgg45	1	22.814	105.103	16.932
## + gleason	1	17.416	110.502	21.790
## + lweight	1	16.041	111.877	22.990
## <none>			127.918	31.412
## + lbph	1	4.136	123.782	32.799
## + age	1	3.679	124.239	33.156

```
##
```

```
## Step: AIC=-39.22
```

```
## lpsa ~ lcavol
```

```
##
```

	Df	Sum of Sq	RSS	AIC
## + lweight	1	5.948	52.966	-44.966
## + svi	1	5.237	53.677	-43.673
## + lbph	1	3.266	55.649	-40.174
## <none>			58.915	-39.217
## + pgg45	1	1.698	57.217	-37.479

Application du cours ($\Rightarrow$ TP4)

- ▶ Charger les données {Prostate.rda}
- ▶ Identifier les meilleurs modèles
 - ▶ par une approche Best subset (pour les différents critères vus en cours)
 - ▶ par une approche Stepwise reposant sur le critère AIC
 - ▶ par une approche Stepwise reposant sur le critère BIC
- ▶ Comparer les résultats et proposer un choix de modèle.

Etude de l'impact de la corrélation sur les méthodes de sélection de variables (=> TP4)

Protocole de simulation permettant d'étudier la performance de 3 méthodes de sélection de variables dans le modèle linéaire :

- ▶ Test de Student de signification des coefficients
- ▶ Recherche exhaustive (Best subset avec l'algorithme Leaps and bound)
- ▶ Algorithme de sélection pas à pas (Stepwise)

Etude de l'impact de la corrélation sur les méthodes de sélection de variables

Dans le cadre de la sélection de variables pour le modèle linéaire, divers phénomènes sont associés à la difficulté du problème. On étudiera en particulier :

- ▶ la structure de dépendance entre les prédicteurs, i.e., la covariance du vecteur $X = (X_1, \dots, X_p)$.
- ▶ le niveau de bruit (variance de ε)
- ▶ le nombre total de prédicteurs considérés (p), le nombre d'observations (n) et le ratio p/n .