

Modèles Linéaires (LM)

Définition

Les **modèles linéaires** (LM) englobent :

- **les modèles de régression linéaire**

↪ les covariables sont des régresseurs : des variables quantitatives

Ex : On explique la teneur en ozone par la température, la nébulosité

- **les modèles d'analyse de la variance** (ANOVA)

↪ les covariables sont des facteurs : des variables qualitatives

Ex : On explique la teneur en ozone par la direction du vent ou la saison

⇒ Tout dépend donc de **la matrice X des covariables ...**

... mais Y n'a pas changé : on cherche à expliquer une mesure numérique !

⇒ On peut aussi mélanger les 2 natures de covariables : **les modèles d'analyse de covariance (ANCOVA)**



Modèle Linéaire || Modèle Linéaire Général || Modèle Linéaire Généralisé

- **Régresseur** : valeur numérique $\Rightarrow$ une infinité de valeurs possibles, souvent toutes différentes dans l'échantillon
 $\hookrightarrow$ une valeur de Y différente pour chaque valeur de X
- **Facteur** : niveau $\Rightarrow$ un nombre fini, faible, de niveaux possibles
 $\hookrightarrow$ répétition des valeurs observées de Y dans chaque niveau

Écriture du modèle

- **Modèle de régression**

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$$

↪ on cherche la part de variabilité de Y induite par les changements de valeurs du régresseur x

↪ 1 paramètre **par régresseur**

↪ signification des paramètres :

β_0 : intercept - niveau moyen de y quand x vaut 0

β_1 : pente - impact d'un accroissement de 1 de x sur la variable réponse

↪ forme de X : ...

● Modèle d'ANOVA

Puisque plusieurs observations de Y pour chaque niveau de x , on note $y_{j,k}$: la réponse de l'individu k dans le niveau j .

$$Y_{j,k} = \beta_0 + \beta_j + \varepsilon_{j,k}$$

↪ on cherche la part de variabilité de Y induite par les différents niveaux du facteur x

↪ 1 paramètre **par niveau du facteur**

↪ signification des paramètres :

β_0 : intercept - valeur moyenne des y observées

β_j : impact du niveau j de x sur la variable réponse

↪ forme de X : ...

Les contraintes dans les modèles d'ANOVA

$$\hat{\beta} = (X'X)^{-1}X'Y$$

- ↪ pour que $X'X$ soit inversible, il faut que X soit de plein rang (colonne) :
- ↪ la dimension de l'espace vectoriel engendré par les colonnes de X est égal à p (le nombre de colonnes de X)

- **Pas d'intercept**

$$\beta_0 = 0$$

- ↪ $\forall j \in \{1, \dots, J\} \quad \beta_j$: valeur moyenne de la réponse dans le niveau j
- ↪ forme de X : ...

- **Choix d'une référence** : un niveau du facteur sert de référence

$$\beta_1 = 0$$

↪ le niveau 1 sert de référence

↪ β_0 valeur moyenne de la réponse dans le niveau 1

↪ $\forall j \in \{2, \dots, J\}$ β_j : écart de la réponse du niveau j au niveau 1

↪ forme de X : ...

↪ Dans R : `contr.treatment`

- **Somme des paramètres**

$$\sum_{j=1}^J \beta_j = 0$$

↪ β_0 moyenne des paramètres

↪ $\forall j \in \{1, \dots, J-1\}$ $\beta_0 + \beta_j$: valeur moyenne de la réponse du niveau j

↪ $\beta_0 - \sum_{j=1}^{J-1} \beta_j$: valeur moyenne de la réponse du niveau J

↪ Dans R : `contr.sum`

ANOVA à 2 facteurs

- Considérons 2 facteurs F_1 (à J_1 modalités) et F_2 (à J_2 modalités).
↪ plusieurs observations de Y à chaque croisement d'une modalité de F_1 et d'une modalité de F_2
- y_{ijk} : observation de l'individu numéro k au croisement du niveau i de F_1 et du niveau j de F_2
- **Modèle :**

$$Y_{ijk} = \beta_0 + \alpha_i + \beta_j + \varepsilon_{ijk}$$

↪ on cherche la part de variabilité de Y induite par chacun des niveaux du facteur F_1 d'une part, et chacun des niveaux du facteur F_2 d'autre part

↪ $1+J_1+J_2$ paramètres

↪ signification des paramètres :

β_0 : intercept - valeur moyenne des valeurs y observées

α_i : impact du niveau i de F_1 sur la variable réponse

β_j : impact du niveau j de F_2 sur la variable réponse

↪ forme de X : ...

● Contraintes

↪ Choix d'une **référence** : niveau 1 de F_1 ($\alpha_1 = 0$) et niveau 1 de F_2 ($\beta_1 = 0$)

↪ $\forall i \in \{2, \dots, J_1\}$ α_i : écart de la réponse du niveau i au niveau 1 de F_1

↪ $\forall j \in \{2, \dots, J_2\}$ β_j : écart de la réponse du niveau j au niveau 1 de F_2

● Additivité des effets principaux

↪ α_i : effet du niveau i de F_1 quelque soit le niveau j de F_2

↪ β_j : effet du niveau j de F_2 quelque soit le niveau i de F_1

● Interaction

↪ On ajoute un effet du niveau i en interaction avec le niveau j : γ_{ij}

↪ Le niveau i de F_1 a un effet différent selon le niveau j de F_2 et réciproquement

↪ Ex : l'orientation du vent n'a pas le même effet avec ou sans pluie

● Modèle

$$Y_{ijk} = \beta_0 + \alpha_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk}$$

↪ Forme de X : ...

↪ Dans R : l'interaction est désignée par $F_1 : F_2$

⇒ Le modèle avec interaction : $Y \sim F_1 + F_2 + F_1 : F_2$ ou $Y \sim F_1 * F_2$

● Contraintes

$$\forall i \in \{1, \dots, J_2\} \quad \gamma_{i1} = 0$$

$$\forall j \in \{1, \dots, J_2\} \quad \gamma_{1j} = 0$$

Modèle d'ANCOVA

La partie explicative du modèle mélange : régresseurs et facteurs.

- X : le régresseur
- F : le facteur

- **Modèle sans interaction** : $Y \sim X + F$

$$Y_{jk} = \beta_0 + \beta_j + \delta x_{jk} + \varepsilon_{jk}$$

↪ forme de X : ...

↪ l'effet du facteur n'a un impact que sur l'intercept

- **Modèle avec interaction** : $Y \sim X * F$

$$Y_{jk} = \beta_0 + \beta_j + (\delta + \delta_j)x_{jk} + \varepsilon_{jk}$$

↪ forme de X : ...

↪ l'effet du facteur a un impact sur l'intercept et sur la pente